DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

Laboratorio de datos

Regresión con KNN

Primer cuatrimestre 2025

¿Cuánto medirá de adulte?

Basado en una clase de Mariela Sued

¿Cuánto medirá de adulte?

- Sin información → ¿Qué podemos decir?

¿Cuánto medirá de adulte?

+ Sin información → ¿Qué podemos decir?

  Recopilemos datos de Altura

¿Cuánto medirá de adulte?

¿Promediamos?

ESTIMAMOS: 173.51

Información

Es varón

¿Cuánto medirá de adulte?

+ Sin información ✅
+ Es varón →

Completemos
columna “sexo”

¿Cuánto medirá de adulte?

¿Promediamos entre varones?

ESTIMAMOS: 179.43

Información

Es varón

La mamá mide 156

¿Cuánto medirá de adulte?

- Sin información → ✅
- Es varón → ✅
- La mamá mide 156 →

Completemos columna
“altura mamá”

¿Qué promediamos ahora?

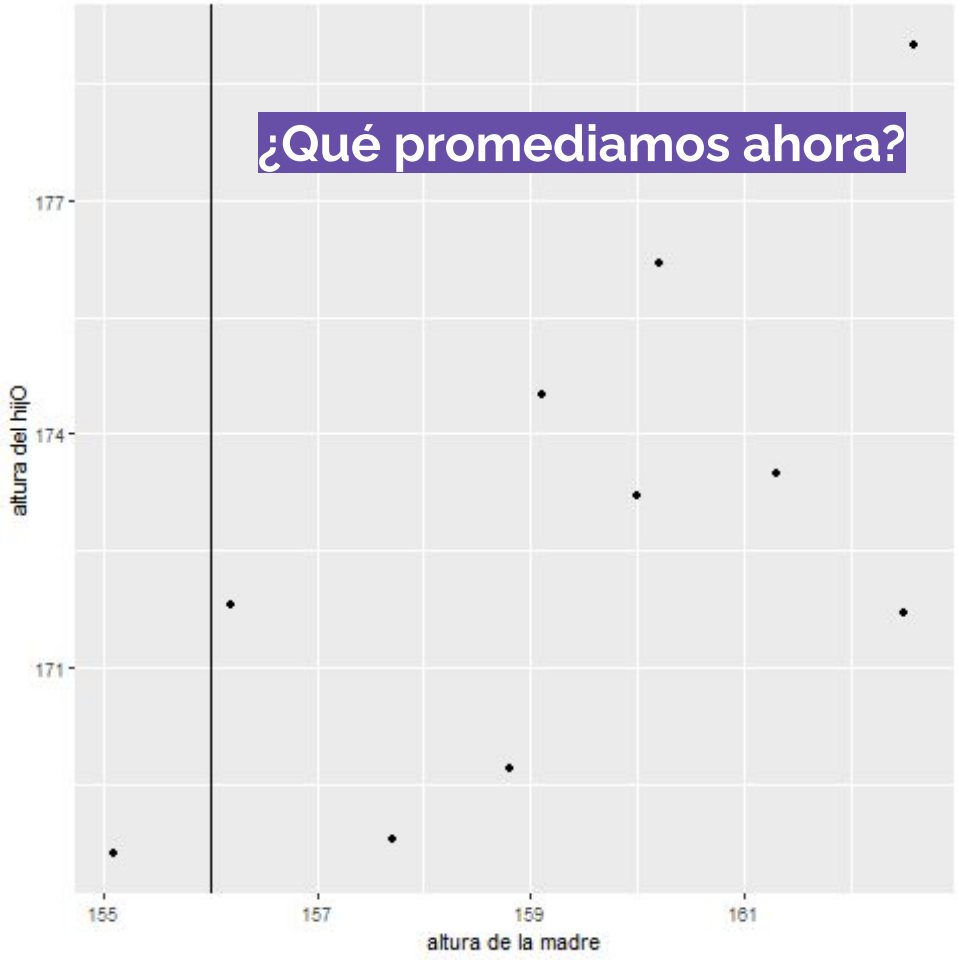

Una posibilidad: KNN

Idea: Promediamos los valores de casos parecidos

kNN: k nearest neighbors - k vecinos más cercanos

Ej. Consideramos los 5 valores más ***cercanos**** al valor nuevo (altura madre). Promediamos las alturas de esos 5 varones

*Cercanos: en la o las variables explicativas, y con la distancia que consideremos.

Estimamos: 177.6

K Nearest Neighbors (KNN) - para regresión

Para determinar el valor de *y* para una nueva observación:

1. Buscar los puntos más cercanos, dentro del conjunto de entrenamiento
2. Ver qué valores de y tienen
3. Promediar

¿Cuántos puntos consideramos? Depende del valor de k.

KNN con sklearn

```
X = data_roundup[["RU"]]
Y = data_roundup["ID"]

modelo_knn = KNeighborsRegressor()
modelo_knn.fit(X,Y)

Y_pred = modelo_knn.predict(X)
mse = mean_squared_error(Y, Y_pred)
```

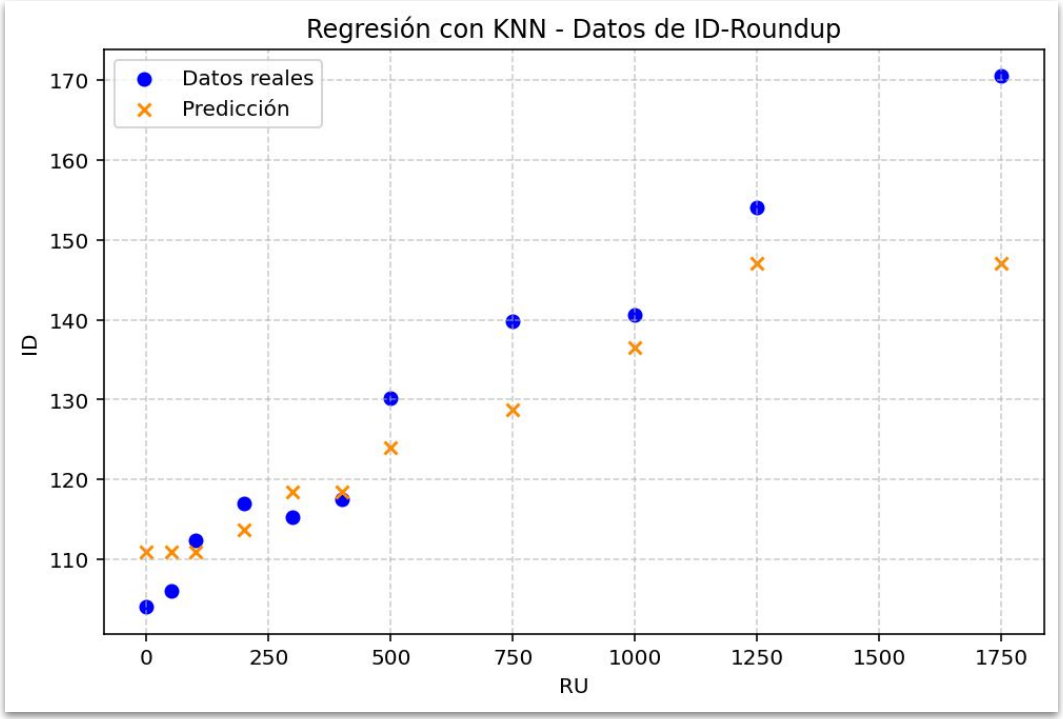

KNN vs Regresión Lineal

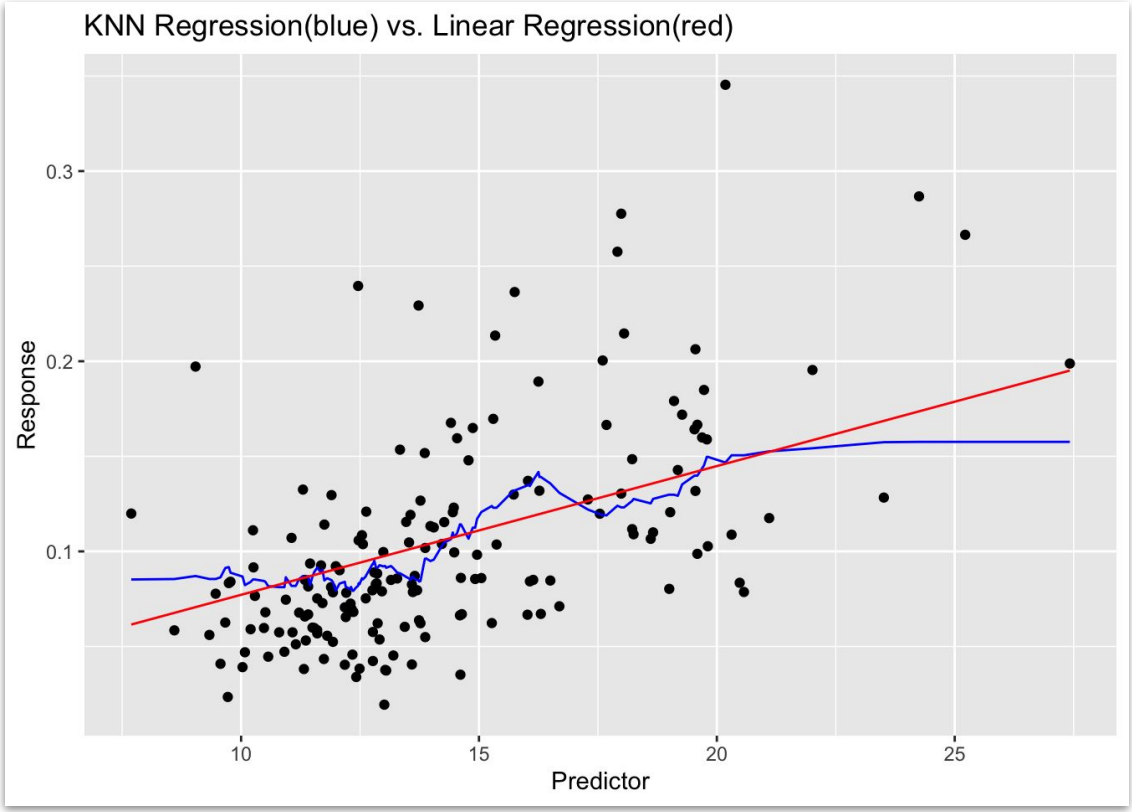

Ejercicio

Ajustar un modelo de regresión con knn para los **datos de altura** relevados con la planilla. Probar con k = 5.

¿Cuán bien funciona?
Reportar el MSE.

Ejercicio

1. Repetir con distintos valores de k.
2. Graficar el MSE para cada valor elegido.

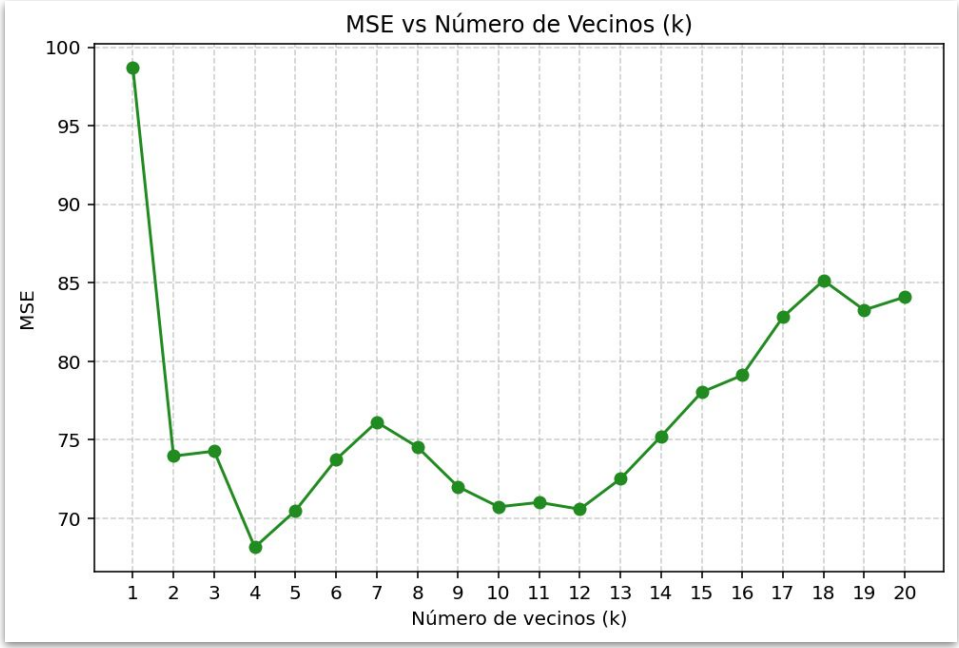

¿Nuestro modelo generaliza bien a otros datos?

Para saberlo, imaginamos 2 escenarios:

- Recibimos datos para ajustar el modelo
- Usamos nuestro modelo en nuevos datos

Para poder simular el segundo escenario, vamos a usar parte de nuestros datos para **ajustar el modelo** *(datos de entrenamiento o train)*, y otra parte para ver **cómo generaliza** *(test)*.

Performance de un modelo - ¿dónde?

Medir la performance sobre datos de entrenamiento no es una buena idea. Surge la necesidad de separar un % de datos, para validar los modelos: datos de validación (o test).

Validación cruzada

Entrenamos nuestro modelo con **algunos** de nuestros datos, y vemos cómo funciona en los **otros** datos.

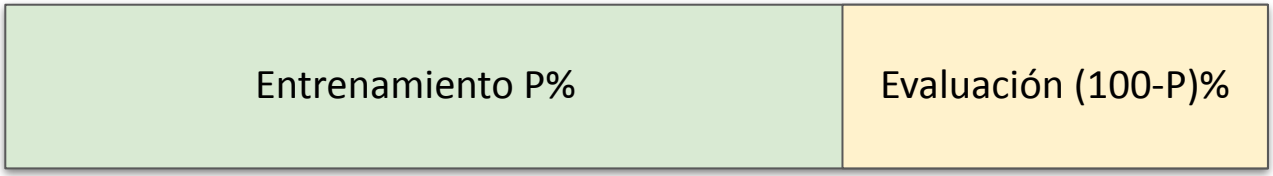

Datos de autos - mpg

Trabajamos con la base de datos sobre autos.
Variable a explicar: mpg.
Variables explicativas:

```
cylinders          int64
displacement     float64
horsepower         int64
weight             int64
acceleration     float64
model year         int64
origin             int64
car name          object
```

Veamos cómo modelarlo con KNN.

Pairplot:
- Scatterplot entre cada par de variables
- Histograma de cada variable

Sirve para ver de manera panorámica las interacciones entre variables.

¿Entre cuáles se ve una tendencia clara?

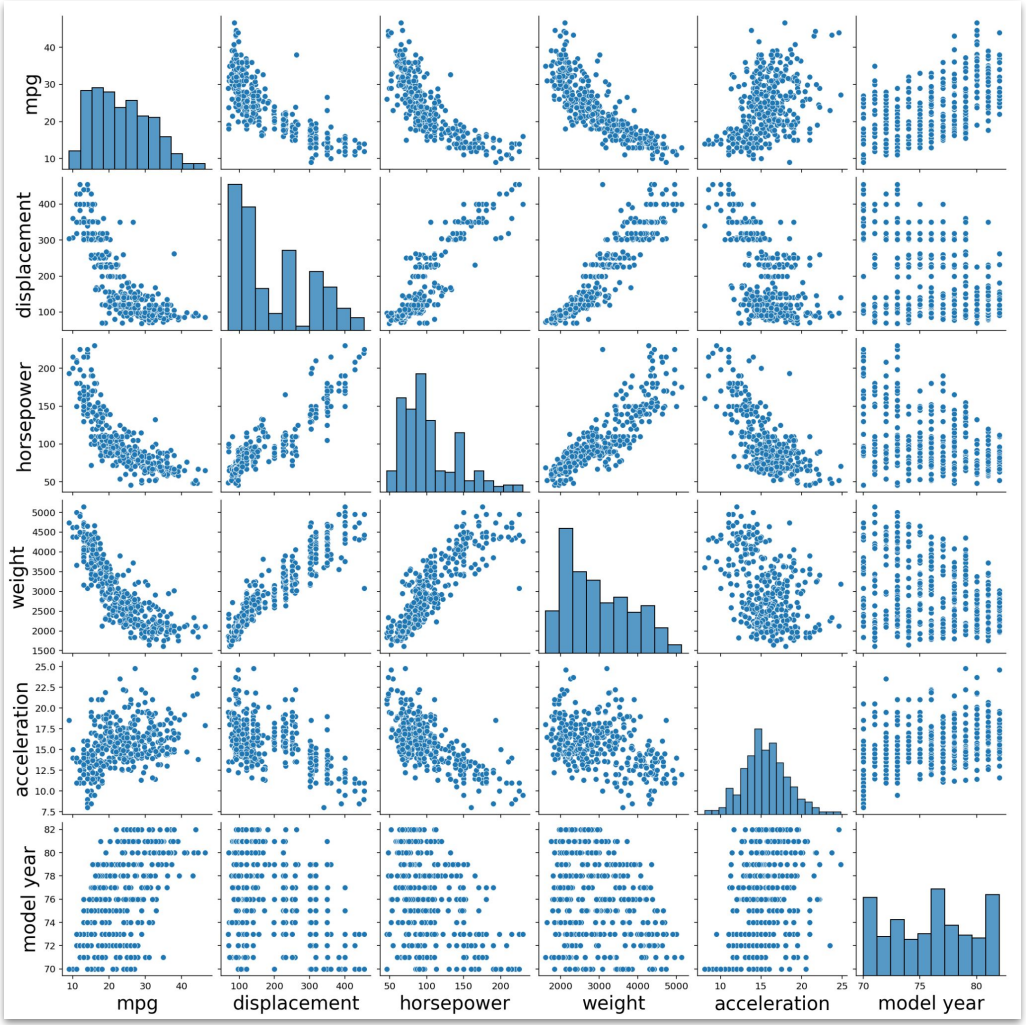

Ejemplo

Mpg respecto de acceleration.

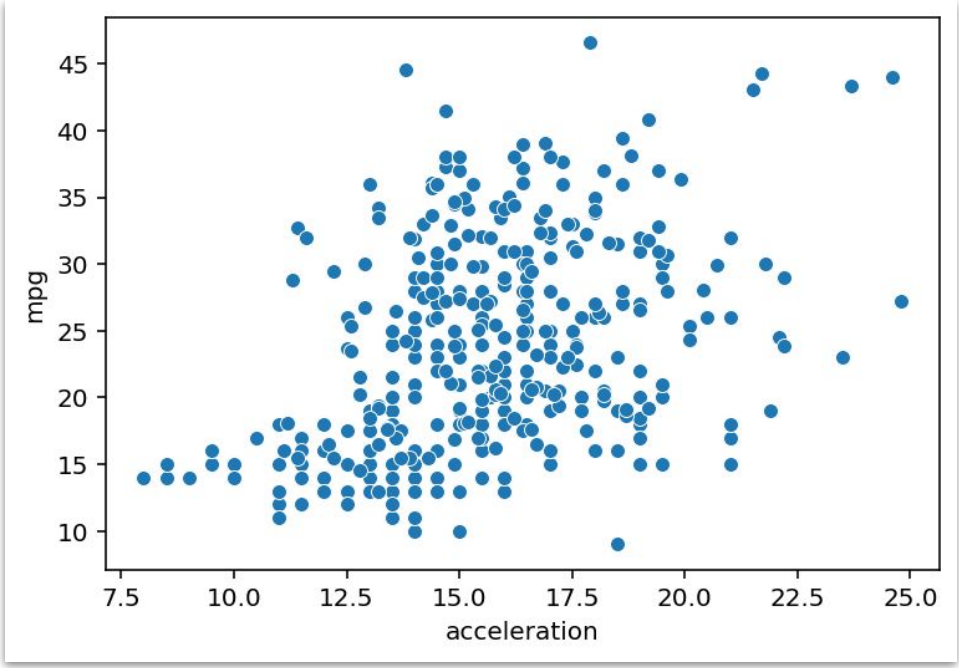

Ejercicio

- Separar el conjunto en train (80%) y test.
- Utilizar knn para ajustar un modelo que prediga mpg en función de acceleration.
- Probar con distintos valores de k, y ver el error en cada caso (MSE).
- Repetir, pero considerando varias variables (elegir cuáles). Antes de hacerlo,
- ¿sería conveniente reescalar los datos?

Ejercicio

- Considerar las variables: 'displacement', 'horsepower', 'weight', 'acceleration', 'model year'
- Separar el conjunto en train (80%) y test.
- Ajustar un modelo knn con k entre 1 y 20, y graficar MSE en función de k, diferenciando train de test.

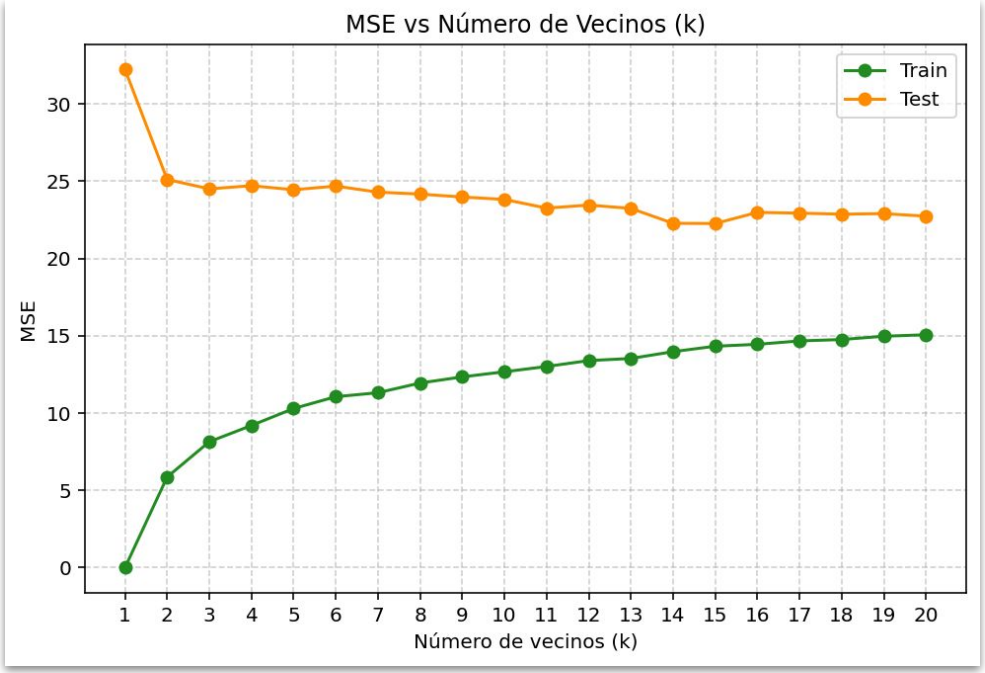

Cierre

- Modelo de KNN para regresión
- Separar en train y test
- Comparar performance en train y en test

Bibliografía

Libros:

- Introduction to Machine Learning with Python, Müller & Guido
- Machine Learning - Mitchell
- Introduction to Statistical Learning with Applications y Python - James, Witten, Hastie, Tibshirani, Taylor